

학생 논문

GRU모델과 교통류 이론을 결합한
교통 예측 모델의 개발에 관한 연구

Nuts

최 우 진

2024년 8월

GRU모델과 교통류 이론을 결합한 교통 예측 모델의 개발에 관한 연구

최 우 진

초록

국문 학위논문의 초록은 국문, 영문의 순서로 작성하며, 영문 학위논문의 초록은 영문, 국문의 순서로 작성하며, 학위논문을 기타 외국어로 작성하는 경우 초록은 기타 외국어, 영문, 국문의 순서로 작성한다. 초록에는 논문제목, 성명, 학과, 지도교수를 기재하며 초록 하단에 주요어(keywords)를 표기한다. 페이지 번호는 초록부터 본문 전까지 작은 로마 숫자(Roman numerals, e.g., i, ii, iii, iv...)를 사용한다.

중심어 : 인공지능, 딥러닝, 빅데이터, 교통류, 교통류 분석, 교통류 예측, 신경망, 심층 신경망, 인공 신경망, 순환 신경망, GRU, 게이트 순환 유닛, 머신러닝, 장단기 기억 신경망, 시계열 데이터, 모델 최적화, 연속 학습, 성능 최적화, 데이터 전처리, 교통 관리 시스템, 예측 모델, 데이터 통합, 모델 평가, 실시간 예측, 데이터 융합, 피드백 함수, 교통 네트워크

A Study on the Development of a Traffic Prediction Model: Combining GRU and Traffic Flow Theory

by Woojin Choi

Abstract

The text of the abstract begins here.

Keywords: Artificial Intelligence, Deep Learning, Big Data, Traffic Flow, Traffic Flow Analysis, Traffic Flow Prediction, Neural Network, Deep Neural Network, Artificial Neural Network, Recurrent Neural Network, GRU, Gated Recurrent Unit, Machine Learning, Long Short-Term Memory, Time Series Data, Model Optimization, Continual Learning, Performance Optimization, Data Preprocessing, Traffic Management System, Prediction Model, Data Integration, Model Evaluation, ARIMA, Real-Time Prediction, Data Fusion, Feedback Function, Traffic Network

목차

초록	i
Abstract	ii
목차	iii
표 목차	iv
그림 목차	v
1장. 서론	1
1.1 연구의 배경 및 목적	1
1.2 연구의 범위 및 방법	3
1.2.1 연구의 범위	3
1.2.2 연구의 방법 및 내용	5
2장. 이론 및 선행연구 고찰	7
2.1 관련 이론 고찰	7
2.1.1 인공 신경망(ANN)	7
2.1.2 신경망 학습	11

2.1.3	순환신경망(RNN)	18
2.2	선행연구 고찰	22
2.2.1	교통류 예측 선행연구	22
참고문헌		24
부록		29
A	부록 첫번째 제목	29
B	부록 두번째 제목	30
색인		31

표 목차

2.1 Interstate I-55 Case Study 결과 22

그림 목차

1.1	표준노드링크 데이터 시각화	4
1.2	연구의 수행 절차	6
2.3	퍼셉트론(Perceptron)	8
2.4	다층 퍼셉트론(Multilayer Perceptron)	9
2.5	ReLU(Rectified Linear Unit)	10
2.6	경사 하강법(Gradient Descent)	13
2.7	드롭아웃(Dropout)	18

1장. 서론

1.1 연구의 배경 및 목적

대한민국의 교통 산업은 1906년 최초의 치도 계획이 수립된 이후 현재까지 지속적으로 성장하였다. 1970년 경부고속도로를 기점으로 현재 대한민국에는 총 51개의 고속도로 노선이 존재한다. 2023년 대한민국의 고속도로 총연장은 4,973km이고, 일반 국도 등을 모두 포함한 총 도로연장은 115,878km에 이른다 [1]. 이 과정에서 국민들의 도로 이용률과 전반적인 활동 범위가 크게 늘어났다. 2023년 대한민국에는 25949대의 자동차가 등록되어 있고, 평균 일교통량은 16051대까지 증가하였다 [2].

그러나 최근에는 자동차의 보급률과 교통량의 증가로 인한 다양한 문제들이 보고되고 있다. 특히 인구의 절반이 수도권에 밀집하여 거주하는 인구분포와 지나친 성장 위주의 교통 정책으로 인한 소통 혼잡과 교통체증등의 사회적, 경제적 문제가 크게 대두되고 있다. 수도권에서는 출퇴근 시간대의 교통 혼잡이 심각하며, 이는 경제적 손실뿐만 아니라 환경 오염과 교통사고의 주요 원인으로 작용하고 있다. 또한 교통체증은 내연기관 자동차 바퀴의 공회전을 유발하기에 경제적 손실뿐만 아니라, 대기오염과 에너지 소비 증가를 초래하여 환경적 문제 또한 가중시키고 있다. 도로 교통망은 국가 경제의 혈관으로서 기능하며, 그 효율성은 국가 전체의 경제활동에 중대한 영향을 미친다. 그러나 최근의 통계는 대한민국의 주요 도시들이 심각한 교통 혼잡에 직면해 있음을 보여준다. 국내 교통혼잡비용은 1994년 10조원 대비 2021

년 45.8조원으로 358% 증가하였다 [3], [4]. 이러한 문제를 해결하기 위해서는 교통 흐름을 정확히 예측하고, 효율적으로 관리할 수 있는 고도화된 교통 예측 모델이 필수적이다.

현재 대한민국의 도로 정책은 교통 혼잡 문제를 해결하기 위한 다양한 방안을 모색하고 있으며, 교통류 예측 모델의 개발과 적용이 그 중심에 있다. 전통적인 교통류 예측 모델들은 주로 수리적 모델과 시계열 예측을 기반으로 하여 교통 흐름을 설명하고 예측하는 데 중점을 두고 있다. 수리적 분석은 Kalman Filter [5], Markov Chain [6] 등의 범용적인 방법과 LWR(Lighthill-Whitham-Richards) 모델 [7], 충격파 이론 [8] 등의 교통류 이론들로 나눌 수 있다. 시계열 예측은 대표적인 모델인 ARIMA(Autoregressive Integrated Moving average Model) [9], [10], [11] 과 계절성을 추가한 SARIMA(Seasonal ARIMA) [12] 등이 주를 이룬다. 수리적 분석은 교통류의 물리적 특성을 반영하여 교통 밀도와 속도 간의 관계를 설명하는 데 강점을 지니며, 시계열 예측은 과거의 데이터를 기반으로 미래의 교통 상황을 예측하는 데 주로 사용된다. 그러나 이러한 모델들은 교통 흐름의 비선형적 특성을 충분히 반영하지 못하며, 복잡한 교통 상황에서의 예측 정확도가 떨어지는 한계를 가지고 있다.

최근 들어 인공지능과 딥러닝 등 기계학습의 발전이 교통류 예측 연구에 새로운 가능성을 열어주고 있다. 기계학습은 Neural Network(NN) [13], [14], [15], [16] 를 중추로 하여 RNN(Recurrent Neural Network) [17], [18], [19], SVR(Support Vector Regression) [20], [21], [22] 등의 회귀 분석 및 학습이 주를 이루고 있다 [23], [24], [25]. 딥러닝 모델, 특히 순환 신경망(RNN)과 같은 시계열 데이터를 다루는 모델들은 교통 데이터의 복잡한 패턴을 학습하고, 이를 기반으로 보다 정교한 예측을 수행할 수 있는 능력을 갖추고 있다. 이로 인해 다양한 교통 상황에서의 예측 정확도가 크게 향상되었으며, 교통 관리와 최적화에 있어 중요한 도구로 자리매김하고 있다. 그러나, 현재까지의 연구는 주로 개별 모델의 성능 향상에 초점을 맞추고 있으며, 서로 다른 모델의 장점을 결합하여 예측 성능을 극대화하려는 시도는 상대적으로 미진한

실정이다.

특히, 교통류 예측 분야에서 결합 모델에 대한 연구는 아직 초기 단계에 머물러 있다. 전통적인 교통류 모델과 딥러닝 모델을 통합하여 예측의 정확성과 신뢰성을 높이려는 시도는 일부 진행되고 있으나, 이러한 연구는 주로 이론적 가능성에 그치고 있다. 결합 모델은 각기 다른 접근법의 장점을 통합함으로써 보다 풍부한 예측 정보를 제공할 수 있는 잠재력을 지니고 있음에도 불구하고, 모델의 복잡성과 데이터 요구 사항으로 인해 실질적인 연구와 실증적 검증이 제한적으로 이루어지고 있다.

본 연구는 이러한 한계를 극복하고, 교통류 예측 모델의 새로운 방향을 제시하기 위해 LWR(Lighthill-Whitham-Richards) 모델 [7], 충격파 이론 [8], 뉴웰의 관성 모델(Newell's Car-Following Model) [26], 그리고 3상 교통 이론(Three-Phase Traffic Theory) [27], [28] 의 교통류 이론들과 GRU(Gated Recurrent Unit) 모델 [29] 을 결합한 새로운 예측 모델을 제안하고자 한다. 교통류 모델들은 차량 간의 상호작용과 흐름의 변화를 설명하는 데 효과적이며, GRU 모델은 시계열 데이터의 장기 의존성을 학습하는 데 탁월한 성능을 보인다. 두 모델의 결합은 교통 흐름의 미시적 특성과 거시적 패턴을 동시에 반영할 수 있는 강력한 예측 도구를 제공할 것으로 기대된다. 따라서, 본 연구의 주요 목적은 교통류 이론과 GRU 모델을 결합하여 교통 흐름의 예측 정확도를 향상시키는 것이다.

1.2 연구의 범위 및 방법

1.2.1 연구의 범위

1) 공간적 범위

결합 모델 및 타 비교 모델들의 학습에 사용된 데이터는 국가교통정보센터의 표준노드링크 위치 데이터에 기반하여 병합되었다. 표준노드링크 데이터는 속도변화

발생점인 노드와 노드를 연결한 선을 의미하는 링크와¹, 차량이 도로를 주행함에 있어 속도의 변화가 발생하는 곳을 표현하는 노드로 구성되어 있으며, 이에 따라 더욱 자세한 도로 정보를 학습할 수 있다 [30]. 노드 데이터는 전국 총 231716개 존재하며, 위치 데이터의 범위는 대한민국 대다수의 주요 도로를 포함하고 있다 Figure 1.1². 노드링크 데이터는 다양한 도로 특성을 가지고 있으며, 고속도로, 국도, 지방도로, 그리고 도시 내 도로를 포함한 다양한 유형의 도로로 구성되어 있다. 표준노드링크 데이터는 2024년 3월 25일 제공된 데이터를 수집하여 사용하였다.



Figure 1.1: 표준노드링크 데이터 시각화

¹즉, 실세계에서의 도로이다.

²shp 파일 시각화 프로그램으로 QGIS를 사용하였다.

2) 시간적 범위

교통 예측을 위해서는 비선형적 특성과 다양한 교통 정보들을 분석해야 한다. 따라서 본 연구는 2023년의 1, 4, 7, 10월의 각종 교통 정보 데이터를 사용하였다. 이러한 시간적 구분은 기상 조건이 교통 흐름에 미치는 영향을 심층적으로 분석하기 위한 전략적 선택에 근거한다. 교통류의 흐름은 계절의 특성과 기상 상태에 따라 크게 좌우되므로, 본 연구에서는 각 분기 첫째 달의 데이터를 사용함으로써 기상 요인에 의한 교통류 패턴을 효율적으로 분석 및 예측 하고자 한다.

1.2.2 연구의 방법 및 내용

본 연구의 내용은 크게 관련 이론 및 기존 연구 고찰, 데이터 구성, 결합 교통 예측 모델 개발, 실험 및 성능 평가로 나뉘어져 있다. 먼저, 본 연구는 교통 예측 모델을 개발 혹은 활용한 기존 연구, 그리고 교통류 이론과 딥러닝 등 본 연구의 관련 이론을 고찰하였다. 그 이후 각종 공공 교통 및 기상 원시 데이터를 수집하여 분석하였다. 수집된 데이터는 분석 및 모델 학습에 적합한 형태로 변환하기 위해 전처리 과정을 거친다. 전처리 과정은 결측치 처리, 이상치 제거, 정규화 등의 단계를 포함하며, 유의 변수를 선정해 분석 데이터의 형태로 가공하여 병합하였다. 이를 통해 데이터의 일관성을 유지하고, 신경망이 효과적으로 학습할 수 있도록 하였다.

본 연구의 핵심은 교통류 이론과 순환 신경망을 효과적으로 개발하여 성능을 입증하는 것이다. 모델 개발 단계에서는 LWR, 충격파 이론 등의 교통류 이론 특성을 분석하고, 적합한 결합 이론을 선정한다. 또 순환 신경망은 결합 모델로서 연산량이 상대적으로 적어 교통류 이론과 결합하여도 연산속도를 보장할 수 있는 GRU로 선정하였다. GRU의 연산속도, 예측 정확도 등을 MAE, MSE, R^2 score 등의 회귀 모델 평가 지표³를 활용하여 검정한다. 최종적으로, 선정된 교통류 이론과 결합 모델의

³MAE, MSE, RMSE, R^2 score를 사용하였다.

특성을 논리적으로 고려하여 교통 예측 결합 모델을 개발하고자 한다.

마지막으로, 개발된 교통 예측 결합 모델과 성능을 비교할 기존의 교통 예측 모델을 프로그래밍 언어 Python을 사용하여 구현한다. 구현된 예측 모델들은 거시적, 미시적 범위로 면밀히 비교되고, 개발된 결합 모델에 종합적인 평가를 내린다. 이 과정을 통해 본 논문의 궁극적 목표인 교통류 이론과 GRU모델을 결합한 개량 교통 예측 모델을 개발하고자 한다 Figure 1.2.




Figure 1.2: 연구의 수행 절차

2장. 이론 및 선행연구 고찰

2.1 관련 이론 고찰

2.1.1 인공 신경망(ANN)

1) 퍼셉트론

퍼셉트론은 프랭크 로젠블랫(Frank Rosenblatt)이 1958년에 제안한 초기 인공신경망 알고리즘이다 [31]. 퍼셉트론은 단층 신경망으로서, 선형 분리 가능한 데이터를 분류하는 데 사용된다. 입, 출력 x_i 과 $\hat{y}$ 은 숫자 값이고 각 입력에 고유 가중치 W_i 을 곱하는 방식으로 분류가 진행된다. 곱해진 값은 모두 합산되어, 활성화 함수인 계단 함수에 전달되어, 결과 $\hat{y}$ 를 출력하게 된다 Figure 2.3.

마빈 민스키(Marvin Minsky)와 시모어 페퍼트(Seymour Papert)가 1969년 단층 퍼셉트론은 베타적 논리합 회로(XOR)조차 해결하지 못한다는 문제를 찾아내었다 [32]. 또한 퍼셉트론 단층 구조의 한계를 지적하며 다층 구조 퍼셉트론을 제안하였다.

$$\hat{y} = f\left(\sum_{i=1}^n W_i x_i\right) \quad f(a) = \begin{cases} 0 & \text{if } a < \beta \\ 1 & \text{if } a \geq \beta \end{cases}$$




Figure 2.3: 퍼셉트론(Perceptron)

2) 다층 퍼셉트론

다층 퍼셉트론(Multilayer Perceptron, MLP)은 인공신경망(Artificial Neural Network, ANN)의 기본적인 구조 중 하나로, 비선형적으로 분리 불가능한 문제를 해결하기 위해 퍼셉트론(Perceptron)의 개념을 확장한 모델이다. 다층 퍼셉트론은 입력층(input layer), 하나 이상의 은닉층(hidden layer)⁴, 그리고 출력층(output layer)으로 구성된다. 각 층은 여러 개의 노드(node)로 이루어져 있으며, 이러한 노드들은 가중치(weight)를 통해 서로 연결되어 있다. 입력층은 외부 데이터의 피쳐(feature)를 받아들이고, 은닉층은 이 데이터를 비선형적으로 변환하며, 출력층은 최종 예측값을 출력하는 역할을 한다.

다층 퍼셉트론과 단층 퍼셉트론의 주요 차이점 중 하나는 은닉층에 활성화 함수(activation function)를 사용하여 비선형성을 도입하는 것이다. 활성화 함수는 신경망이 단순히 선형 분류 가능 데이터만을 학습하는 것이 아닌, 비선형적인 복잡한 데이터를 분류하게 해준다. 일반적으로 사용되는 활성화 함수로는 시그모이드(sigmoid) 함수, 하이퍼볼릭 탄젠트(hyperbolic tangent, tanh) 함수, 그리고 ReLU(Rectified

⁴은닉층이 2개 이상인 신경망을 심층 신경망(Deep Neural Network, DNN)이라고 한다.

Linear Unit) 함수 등이 있다.




Figure 2.4: 다층 퍼셉트론(Multilayer Perceptron)

3) 활성화 함수

활성화 함수란 입력값을 받아 특정 연산을 수행한 후, 출력값을 통해 그 신호가 다음 단계에서 활성화되는지를 결정하는 함수이다. 신경망에서 활성화 함수는 매우 중대한 역할을 하며, 출력된 값이 다음 층의 뉴런에 전달되는지를 결정한다. 초기에는 퍼셉트론과 같은 단순한 신경망에서 0과 1의 값만을 출력하는 계단 함수(step function)가 사용되었으나, 정보가 축소되어 손실된다는 단점으로 현재는 거의 사용되지 않는다. 이를 개선하기 위해, 0과 1 사이의 연속적인 값을 출력하는 시그모이드(Sigmoid) 함수가 일반적으로 많이 사용되었다. 시그모이드 함수는 각 뉴런의 출력값을 0과 1 사이로 매핑하여, 뉴런이 활성화될 확률을 출력한다. 그러나 시그모이드 함수는 입력 값이 크거나 작을 때 기울기가 0에 가까워지는 기울기 소실(Vanishing Gradient) 문제를 일으킬 수 있다는 단점이 있다. 이와 같은 문제를 해결하기 위해 많이 사용되는 활성화 함수 중 하나가 ReLU(Rectified Linear Unit) 함수이다. ReLU 함수는 입력이 0보다 클 때는 입력 값을 그대로 출력하고, 0 이하일 때는 0을 출력하

는 함수이다 Figure 2.5.

$$\text{ReLU}(x) = \max(0, x)$$




Figure 2.5: ReLU(Rectified Linear Unit)

4) 신경망 노드

조지 시벤코(George Cybenko)는 1989년 은닉층의 노드 수가 무한대에 가까워질 경우, 은닉층이 하나만 있어도 어떠한 연속 함수도 근사할 수 있다는 유니버설 근사 정리(Universal Approximation Theorem)를 제시하였다 [33]. 이 이론은 신경망이 충분히 많은 노드를 갖춘 경우, 복잡한 함수도 정확하게 모델링할 수 있음을 시사한다. 그러나, 심층 신경망(Deep Neural Networks)은 동일한 기능을 수행하는데 있어서, 일반 신경망보다 파라미터의 효율성이 높다는 장점이 있다. 특히, 복잡한 함수를 모델링할 때 심층 신경망은 적은 수의 노드로도 동일한 성능을 발휘할 수 있어 학습 시간을 단축시키는 효과가 있다. 입력층(Input Layer)과 출력층(Output Layer)의 노드 수는 주어진 문제의 특성에 맞춰 필요한 입출력 형태에 따라 결정된

다. 예를 들어, 입력 데이터의 차원이 높다면 입력층의 노드 수가 많아지고, 출력이 다중 분류 문제일 경우 출력층의 노드 수도 이에 맞게 조정된다. 신경망은 저수준의 많은 특성을 고수준의 적은 특성으로 통합하는 형태로 층(layer)을 구성할 수 있으며, 이는 데이터의 복잡한 구조를 단계적으로 추출하고 간소화하는 데 기여한다. 또한, 은닉층(Hidden Layer)의 노드 수를 고정시키고 은닉층의 개수를 늘리는 방식으로 신경망을 구성할 수도 있다.

2.1.2 신경망 학습

인공 신경망은 학습 과정에서 여러 가지 문제가 발생할 수 있다. 이러한 문제들은 신경망의 성능을 저하시킬 수 있으며, 모델이 효과적으로 학습하지 못하도록 방해한다.

기울기 소실 및 폭주

기울기 소실 문제는 신경망의 학습 과정에서 역전파 알고리즘을 사용하는 중에 발생한다. 이 문제는 네트워크의 층이 깊어질수록 손실 함수의 기울기가 점점 작아져, 초기 층의 가중치가 거의 업데이트되지 않게 되는 현상을 말한다. 이는 신경망이 충분히 학습되지 않게 하여, 인공 신경망이 데이터의 패턴을 제대로 학습하지 못하게 만든다. 기울기 폭주 문제는 역전파 과정에서 기울기가 지나치게 커져 가중치가 불안정하게 증가하는 현상을 의미한다. 기울기 폭주 문제는 주로 깊은 신경망이나 재귀 신경망에서 나타나며, 인공 신경망의 학습이 수렴하지 않고 발산하게 만들어 성능을 저하시킬 수 있다.

과적합

과적합은 신경망이 훈련 데이터에 지나치게 맞춰져, 새로운 데이터나 테스트 데이터에서 성능이 저하되는 현상을 의미한다. 이는 모델이 훈련 데이터의 잡음까지

학습하여, 일반화 능력이 떨어지게 되는 것이다. 과적합된 모델은 실제 데이터에서 좋은 성능을 보이지 못하며, 이는 신경망이 새로운 데이터를 학습하는 데 어려움을 겪게 만든다.

데이터 편향 및 불균형

데이터가 편향되어 있거나 불균형할 경우, 신경망은 특정 패턴이나 클래스에 대해 편향된 학습을 하게 된다. 이는 예측 모델의 성능을 왜곡시키고, 특정 클래스나 패턴을 과소, 과대평가하게 만들어 신경망의 학습 결과에 부정적인 영향을 미친다.

1) 옵티마이저

옵티마이저(Optimizer)는 신경망 학습에서 모델의 가중치를 업데이트하는 알고리즘으로, 손실 함수(Loss Function)의 값을 최소화하여 모델의 성능을 향상시키는 데 중요한 역할을 한다. 신경망은 주어진 입력 데이터에 대한 예측 값을 출력하고, 그 예측이 실제 값과 얼마나 차이가 있는지를 손실 함수를 통해 평가한다. 옵티마이저는 이 손실 값을 최소화하기 위해 모델의 가중치 매개변수(parameter)를 조정하여, 예측 성능을 향상시킨다.

옵티마이저는 손실 함수의 현재 지점 기울기(Gradient)를 계산하여, 손실 함수의 값이 줄어들 수 있는 방향으로 전역 최소점(Global Minimum)을 찾아 모델의 매개변수를 업데이트하는 것이다⁵. 기울기는 손실 함수의 값이 어떻게 변하는지를 나타내는 지표로, 편미분을 통해 기울기가 큰 방향으로 매개변수를 이동시키면 손실 값이 감소하게 된다. 이 과정은 경사 하강법(Gradient Descent)을 기반으로 하며, 신경망의 학습 과정에서 반복적으로 수행된다 Figure 2.6. 경사 하강법은 함수의 기울기를 구하여 기울기가 낮은 쪽으로 계속 이동시켜 미분값이 0이 되는 지점까지 반복하는

⁵전역 최소점(Global Minimum)을 찾는 과정에서 함수가 비선형성을 띠는 경우, 신경망이 지역 최소점(Local Minima)에 빠질 수 있다.

옵티마이징 방법이다. 최적화할 함수 $f(x)$ 에서 시작점 x_0 를 정하고, x_i 가 주어지면, 다음 이동점인 $x_i + 1$ 가 산출된다. 이때 γ_i 는 한번의 연산에서 이동할 폭을 조절하는 하이퍼 파라미터로 학습률(learning rate)라 한다. 학습률을 크게 하면 발산되고 작게 하면 수렴이 되지 않아 전역 최소점 탐색에 차질이 생기기 때문에 적절한 값을 설정해야 한다.

$$x_{i+1} = x_i - \gamma_i \nabla f(x_i)$$




Figure 2.6: 경사 하강법(Gradient Descent)

가. 모멘텀 옵티마이저(Momentum Optimizer)

보리스 폴락(Boris T. Polyak)이 1964년 발표한 옵티마이저인 모멘텀 옵티마이저는 기존 경사 하강법에 실세계의 물리 법칙을 결합시킨 방법이다. 모멘텀 옵티마이저는 느리게 출발하여 특정 시점부터 가속되는 관성의 원리가 적용되어 있다. 모멘텀 옵티마이저는 이전 기울기(Gradient)의 방향과 크기를 일정 부분 유지하면서 새로운 기울기를 반영하여, 더욱 빠르고 안정적인 수렴을 도모한다.

모멘텀 옵티마이저는 각 업데이트 단계에서 이전 단계의 이동 방향을 일정 부분 유지하는 방식을 채택한다. 이를 통해, 기울기가 지속적으로 동일한 방향으로 작용하는 경우에는 업데이트 속도를 가속화하고, 반대로 기울기가 자주 변하는 경우에는 진동을 줄여 안정적으로 수렴할 수 있게 한다.

$$v_{t+1} = \beta v_t + (1 - \beta) \nabla f(x_t)$$

$$x_{t+1} = x_t - \eta v_{t+1}$$

여기서 v_t 는 시간 t 에서의 이동 속도(velocity)를 나타내며, β 는 모멘텀 계수(momentum coefficient)로, 일반적으로 0과 1 사이의 값을 갖는다. $\nabla f(x_t)$ 는 현재 지점 x_t 에서의 손실 함수 $f(x)$ 의 기울기이며, η 는 학습률(learning rate)이다. 모멘텀 계수 β 는 이전 이동 속도를 얼마나 반영할지를 결정하는 파라미터로, 값이 클수록 관성이 크게 작용하여 이동 방향이 더 강하게 설정된다.

나. AdaGrad

AdaGrad(Adaptive Gradient Algorithm)는 기계 학습과 딥러닝 모델의 최적화를 위한 경사하강법(Gradient Descent) 기반의 옵티마이저 중 하나로, 2011년 John Duchi, Elad Hazan, Yoram Singer에 의해 제안되었다. AdaGrad는 학습률(Learning Rate)을 각 매개변수에 대해 각 매개변수의 과거 기울기 제곱합의 역수에 비례하여 학습률을 조정합니다. 이를 통해, 자주 업데이트되는 매개변수의 학습률은 감소시키고, 드물게 업데이트되는 매개변수의 학습률은 증가시킨다.

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{G_t + \epsilon}} \nabla f(\theta_t)$$

$$G_t = \sum_{i=1}^t \nabla f(\theta_i)^2$$

- θ_t 는 시간 t 에서의 매개변수
- η 는 초기 학습률
- G_t 는 시간 t 까지의 기울기 제곱합
- $\nabla f(\theta_t)$ 는 현재 지점에서의 손실 함수의 기울기
- ϵ 은 0으로 나누는 것을 방지하기 위한 작은 값

다. RMSProp

AdaGrad의 단점을 해결하기 위해 제프리 힌튼이 제안한 알고리즘이다. 아래의 식과 같이 AdaGrad의 기울기의 제곱값을 더해 구한 G_t 를 지수평균으로 사용한다.

$$G = \gamma G + (1 - \gamma)(\nabla_{\theta} J(\theta))^2$$

$$\theta = \theta - \frac{\eta}{\sqrt{G + \epsilon}} \nabla_{\theta} J(\theta)$$

라. Adam

Adam(Adaptive Moment Estimation) 옵티마이저는 2014년 Diederik P. Kingma와 Jimmy Lei Ba에 의해 제안되었다. Adam은 학습 과정에서 각 매개변수의 1차 모멘트(기울기의 평균)와 2차 모멘트(기울기의 제곱 평균)를 동시에 고려하여, 학습률을 적응적으로 조정한다.

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla f(\theta_t)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2)(\nabla f(\theta_t))^2$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t$$

- m_t 는 시간 t 에서의 1차 모멘트(기울기의 지수 이동 평균)
- v_t 는 시간 t 에서의 2차 모멘트(기울기 제곱의 지수 이동 평균)
- β_1 와 β_2 는 각각 1차와 2차 모멘트의 지수 이동 평균을 계산할 때 사용되는 감쇠 계수(decay rate)
- $\hat{m}_t$ 와 $\hat{v}_t$ 는 편향을 보정한 1차와 2차 모멘트 추정치
- η 는 학습률(learning rate)
- ϵ 은 수치적 안정성을 위해 사용되는 작은 상수이다

2) 오차 역전파

오차 역전파(Backpropagation)은 1986년 데이비드 E. 루멜하트(David E. Rumelhart), 제프리 힌튼(Geoffrey Hinton), 로널드 J. 윌리엄스(Ronald J. Williams)에 의해 체계적으로 정립되었다. 이 알고리즘은 다층 퍼셉트론(Multilayer Perceptron,

MLP)과 같은 심층 신경망(Deep Neural Networks)의 학습에서 사용되며, 네트워크의 출력을 실제 값에 근사시키기 위해 가중치(weight)와 편향(bias)을 조정한다. 오차 역전파 알고리즘은 네트워크의 출력층에서 계산된 오차를 기준으로, 오차를 네트워크의 각 층을 거슬러 올라가며 전파함으로써 각 가중치에 대한 손실 함수(Loss Function)의 기울기를 계산한다. 이를 통해, 신경망은 출력값과 실제 목표값 간의 오차를 최소화하기 위해 각 층의 가중치를 업데이트하게 된다.

오차 역전파 알고리즘은 두 단계로 나뉜다. 첫 번째 단계는 순전파 단계(Forward Pass)로, 입력 데이터를 신경망에 통과시키면서 각 층의 유닛을 활성화하고 최종 출력층에 도달하여 예측값을 생성한다. 이 과정에서 각 유닛은 활성화 함수(Activation Function)를 통해 비선형 변환을 수행한다. 두 번째 단계는 역전파 단계(Backward Pass)로, 출력층에서 계산된 오차를 바탕으로 네트워크의 가중치에 대한 손실 함수의 기울기를 계산한다. 이때 체인 룰(chain rule)을 사용하여, 출력층에서 시작하여 입력층 방향으로 오차를 전파하면서 각 가중치의 기울기를 계산한다.

$$\delta_j^l = \left(\sum_k \delta_k^{l+1} w_{jk}^{l+1} \right) f'(z_j^l)$$

여기서 δ_j^l 는 층 l 에 있는 뉴런 j 의 오차, w_{jk}^{l+1} 는 층 $l+1$ 의 뉴런 k 로의 가중치, $f'(z_j^l)$ 는 뉴런 j 의 활성화 함수의 도함수이다. 이를 이용해 각 가중치 w_{ij}^l 에 대한 손실 함수의 기울기 $\frac{\partial L}{\partial w_{ij}^l}$ 를 구할 수 있다.

$$w_{ij}^l = w_{ij}^l - \eta \frac{\partial L}{\partial w_{ij}^l}$$

5) 드롭아웃

드롭아웃은 2012년 제프리 힌튼에 의해 제안되었다. 매 학습에서 각 노드는 임의적으로 드롭아웃될 확률 p 를 가지게 되며, 노드 간의 연결을 임의로 삭제할 수 있다.

드롭아웃은 신경망이 데이터의 잡음이나 불규칙성에 덜 민감하게 반응하도록 하여, 테스트 데이터에서의 성능을 개선한다 Figure 2.7.




Figure 2.7: 드롭아웃(Dropout)

2.1.3 순환신경망(RNN)

1) 완전 순환 신경망

완전 순환 신경망(Fully Recurrent Neural Network, FRNN)은 순환 신경망(Recurrent Neural Network, RNN) 구조 중 하나로, 모든 뉴런이 다른 모든 뉴런과 연결되어 있다. 이 구조는 각 뉴런이 자신을 포함한 다른 모든 뉴런으로부터 입력을 받도록 하여, 내부의 모든 정보가 시간에 따라 지속적으로 순환한다. 완전 순환 신경망은 시계열 데이터 같은 시간에 따른 패턴을 학습하는 데 적합한 모델로, 특히 시퀀스 데이터(sequence data)에서의 복잡한 상호 의존성을 효과적으로 포착한다.

$$h_t = f(W \cdot h_{t-1} + U \cdot x_t + b)$$

- h_t 는 시간 t 에서의 은닉 상태(hidden state)
- W 는 은닉 상태 간의 가중치 행렬(weight matrix)
- U 는 입력 x_t 에 대한 가중치 행렬

- x_t 는 시간 t 에서의 입력 벡터
- b 는 편향 벡터(bias vector)
- f 는 비선형 활성화 함수(activation function)

2) 엘만 신경망

엘만 신경망(Elman Neural Network, ENN)은 1990년 제프리 엘만(Jeffrey L. Elman)에 의해 제안되었다. 엘만 신경망은 기본적으로 입력층(Input Layer), 은닉층(Hidden Layer), 그리고 출력층(Output Layer)의 세 개 층으로 구성되었다. 은닉층의 출력이 맥락 유닛(Context Units)에 저장되며, 이 맥락 유닛이 다음 시점의 입력과 함께 은닉층으로 다시 전달된다.

$$h_t = \sigma_h(W \cdot x_t + U \cdot h_{t-1} + b_h)$$

$$y_t = \sigma_y(V \cdot h_t + b_y)$$

- x_t 는 시간 t 에서의 입력 벡터
- h_t 는 시간 t 에서의 은닉 상태
- y_t 는 시간 t 에서의 출력
- W, U, V 는 각각 입력, 은닉 상태, 출력에 대한 가중치 행렬
- b_h, b_y 는 은닉층과 출력층의 편향 벡터
- σ_h 와 σ_y 는 각각 은닉층과 출력층의 활성화 함수

3) 엘만 신경망

조르단 신경망은 엘만 신경망과 비슷하나, 맥락 유닛(Context Units)에서 은닉 레이어가 아닌 출력 레이어로부터 값을 받는다.

$$h_t = \sigma_h(W \cdot x_t + U \cdot y_{t-1} + b_h)$$

$$y_t = \sigma_y(V \cdot h_t + b_y)$$

4) LSTM

LSTM(Long Short-Term Memory) 장기 의존성(Long-Term Dependencies)을 효과적으로 학습하기 위해 1997년 호흐라이터(Sepp Hochreiter)와 슈미드후버(Jürgen Schmidhuber)에 의해 처음 제안되었다. LSTM 네트워크는 정보의 흐름을 조절하는 여러 개의 게이트(gates)를 통해 데이터를 처리하여, RNN의 기울기 소실(Vanishing Gradient) 문제를 해결하였다. 기본적인 LSTM 셀은 입력 게이트(Input Gate), 망각 게이트(Forget Gate), 출력 게이트(Output Gate)로 구성되어 있으며, 이 게이트들은 정보가 셀 상태(Cell State)를 통해 전달되는 방식을 통제한다.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \odot \tanh(C_t)$$

- x_t 는 시간 t 에서의 입력 벡터
- h_t 는 시간 t 에서의 은닉 상태
- C_t 는 시간 t 에서의 셀 상태
- W_f, W_i, W_C, W_o 는 각 게이트에 대한 가중치 행렬
- b_f, b_i, b_C, b_o 는 각 게이트의 편향 벡터
- σ 는 시그모이드 활성화 함수
- $\tanh$ 는 하이퍼볼릭 탄젠트 활성화 함수
- $\odot$ 는 원소별 곱(element-wise multiplication)

5) GRU

GRU(Gated Recurrent Unit)은 2014년 조경현(KyungHyun Cho)이 제안한 모델이다. GRU는 장단기 메모리(Long Short-Term Memory, LSTM) 네트워크의 성능을 유지하면서도 구조를 단순화하여 계산 효율성을 높였다. GRU는 LSTM과 마찬가지로 기울기 소실(Vanishing Gradient) 문제를 완화하고, 장기 의존성을 효과적으로 학습한다.

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z)$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r)$$

$$\tilde{h}t = \tanh(W_h \cdot [r_t \odot ht - 1, x_t] + b_h)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

2.2 선행연구 고찰

2.2.1 교통류 예측 선행연구

Nicholas G. Polson, Vadim O. Sokolov(2017)은 l_1 정규화를 사용하여 학습한 선형 교통류 예측 모델과 tanh층을 결합한 모델 아키텍처를 개발하고, 성능 검증을 완료하였다. $f \in \{\tanh(x), \max(x, 0)\}$, $n \in \{1, \dots, 60\}$, $N_l \in \{1, \dots, 200\}^n$, $k \in [10^{-4}, 10^{-2}]$, $x_{t+h}^t = f_n \circ \dots \circ f_1(x_t)$, $f_l = f(w_l^T x_l + b_l)$. 연구의 Case Study는 Chicago의 Interstate I-55 으로 진행됐고, 결과는 다음과 같았다 Table 2.1. B.

	DLL	DLM8L	DLM8	DLTF15L	DLTF15	VARM8L	VARTF15L
IS MSE	13.58	7.7	10.62	12.55	12.59	8.47	15
IS R^2	0.72	0.83	0.76	0.75	0.75	0.81	0.7
OS MSE	13.9	8.0	9.5	11.17	12.34	8.78	15.35
OS R^2	0.75	0.85	0.82	0.81	0.79	0.83	0.74

Table 2.1: Interstate I-55 Case Study 결과

Gültekin Çetiner, Murat Sari, Oğuz Borat(2010)은 이스탄불의 이스탄불 교통 유지 관리 부서(ISBAK)에서 제공된 도로 교통 데이터를 기반으로 기본 인공신경망(ANN)을 사용하여 예측 분석을 진행하였다. 130,701개의 값으로 구성된 데이터셋

을 사용하고 학습되었고, 상관 계수 0.93⁶과, 0.8⁷이라고 고무적인 결과를 내었다.

Hongsuk Yi, HeeJin Jung(2017)은 Google의 TensorFlow™기반의 DNN(Deep Neural Network)을 사용하여 교통 혼잡도를 예측하였다. 제안된 TensorFlow™ DNN 모델은 3개의 레이어로 구성되었으며, 각각 40, 50, 40개의 뉴런을 포함했다. 이 모델은 하이퍼탄젠트 함수(tanh)를 활성화 함수로 사용하며, 약 99%의 정확도로 교통 흐름 상태를 예측할 수 있음을 보였다.

Guo Xiaojian, Zhu Quan(2009)은 BP 신경망(Backpropagation Neural Network)을 사용하여 2008년 6월 20일부터 7월 25일까지 중국 간저우시에 위치한 홍치 교차로의 역사적 데이터를 학습시켰다. 예측 정확도는 약 85%에 달하며, 이는 인공 신경망 교통 예측 모델의 가능성을 알렸다.

⁶훈련 세트의 처음 20,000개 데이터로 훈련되었으며, 테스트는 나머지 테스트 세트를 통해 수행된 결과

⁷각각 1-1,000 및 1,001-2,015의 범위로 훈련 및 테스트 세트로 나뉘어서 수행된 결과

참고문헌

- [1] 국토교통부, “도로현황조서,” 2023.
- [2] 국토교통부, “2023년 도로 교통량 조사,” 2023.
- [3] 한국교통연구원, “전국 교통혼잡비용 산출과 추이 분석,” 1994–2012.
- [4] 한국교통연구원, “국가 교통정책 평가지표 조사사업,” 2016–2021.
- [5] R. E. Kalman, “A New Approach to Linear Filtering and Prediction Problems,” *Journal of Basic Engineering*, vol. 82, pp. 35–45, 03 1960.
- [6] Марков, “Распространение закона больших чисел на величины, зависящие друг от друга,” *Известия физико-математического общества при Казанском университете*, vol. 15, no. 2, p. 135, 1906.
- [7] M. J. Lighthill and G. B. Whitham, “On kinematic waves ii. a theory of traffic flow on long crowded roads,” *Proceedings of the royal society of london. series a. mathematical and physical sciences*, vol. 229, no. 1178, pp. 317–345, 1955.
- [8] P. I. Richards, “Shock waves on the highway,” *Operations research*, vol. 4, no. 1, pp. 42–51, 1956.

- [9] G. E. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time series analysis: forecasting and control*. John Wiley & Sons, 2015.
- [10] M. Van Der Voort, M. Dougherty, and S. Watson, “Combining kohonen maps with arima time series models to forecast traffic flow,” *Transportation Research Part C: Emerging Technologies*, vol. 4, no. 5, pp. 307–318, 1996.
- [11] N. Lihua, C. Xiaorong, and H. Qian, “Arima model for traffic flow prediction based on wavelet analysis,” in *The 2nd International Conference on Information Science and Engineering*, pp. 1028–1031, 2010.
- [12] S. V. Kumar and L. Vanajakshi, “Short-term traffic flow prediction using seasonal ARIMA model with limited input data,” *European Transport Research Review*, vol. 7, p. 21, June 2015.
- [13] N. G. Polson and V. O. Sokolov, “Deep learning for short-term traffic flow prediction,” *Transportation Research Part C: Emerging Technologies*, vol. 79, pp. 1–17, 2017.
- [14] B. G. Çetiner, M. Sari, and O. Borat, “A neural network based traffic-flow prediction model,” *Mathematical and Computational Applications*, vol. 15, no. 2, pp. 269–278, 2010.
- [15] H. Yi, H. Jung, and S. Bae, “Deep neural networks for traffic flow prediction,” in *2017 IEEE International Conference on Big Data and Smart Computing (BigComp)*, pp. 328–331, 2017.

- [16] G. Xiaojian and Z. Quan, “A traffic flow forecasting model based on bp neural network,” in *2009 2nd International Conference on Power Electronics and Intelligent Transportation System (PEITS)*, vol. 3, pp. 311–314, 2009.
- [17] D. Kang, Y. Lv, and Y.-y. Chen, “Short-term traffic flow prediction with lstm recurrent neural network,” in *2017 IEEE 20th International Conference on Intelligent Transportation Systems (ITSC)*, pp. 1–6, 2017.
- [18] Y. Tian and L. Pan, “Predicting short-term traffic flow by long short-term memory recurrent neural network,” in *2015 IEEE International Conference on Smart City/SocialCom/SustainCom (SmartCity)*, pp. 153–158, 2015.
- [19] R. Fu, Z. Zhang, and L. Li, “Using lstm and gru neural network methods for traffic flow prediction,” in *2016 31st Youth Academic Annual Conference of Chinese Association of Automation (YAC)*, pp. 324–328, 2016.
- [20] Z. Mingheng, Z. Yaobao, H. Ganglong, and C. Gang, “Accurate multisteps traffic flow prediction based on svm,” *Mathematical Problems in Engineering*, vol. 2013, no. 1, p. 418303, 2013.
- [21] Y.-n. Yang and H.-p. Lu, “Short-term traffic flow combined forecasting model based on svm,” in *2010 International Conference on Computational and Information Sciences*, pp. 262–265, 2010.
- [22] L. Liu, “A short-term traffic flow prediction method based on svr,” in *2021 2nd International Conference on Urban Engineering and Management Science (ICUEMS)*, pp. 1–4, 2021.

- [23] J. J. Hopfield, “Neural networks and physical systems with emergent collective computational abilities.,” *Proceedings of the national academy of sciences*, vol. 79, no. 8, pp. 2554–2558, 1982.
- [24] C. Cortes, “Support-vector networks,” *Machine Learning*, 1995.
- [25] V. Vapnik, *The nature of statistical learning theory*. Springer science & business media, 2013.
- [26] G. F. Newell, “Nonlinear effects in the dynamics of car following,” *Operations research*, vol. 9, no. 2, pp. 209–229, 1961.
- [27] B. S. Kerner, “Experimental features of self-organization in traffic flow,” *Phys. Rev. Lett.*, vol. 81, pp. 3797–3800, Oct 1998.
- [28] B. S. Kerner, “Congested traffic flow: Observations and theory,” *Transportation Research Record*, vol. 1678, no. 1, pp. 160–167, 1999.
- [29] K. Cho, “Learning phrase representations using rnn encoder-decoder for statistical machine translation,” *arXiv preprint arXiv:1406.1078*, 2014.
- [30] 국가교통정보센터, “노드링크 소개,”
- [31] F. Rosenblatt, “The perceptron: a probabilistic model for information storage and organization in the brain.,” *Psychological review*, vol. 65, no. 6, p. 386, 1958.
- [32] M. Minsky and S. Papert, “An introduction to computational geometry,” *Cambridge tiass., HIT*, vol. 479, no. 480, p. 104, 1969.

- [33] G. Cybenko, “Approximation by superpositions of a sigmoidal function,” *Mathematics of control, signals and systems*, vol. 2, no. 4, pp. 303–314, 1989.

부록

A 부록 첫번째 제목

필요한 경우 부록(appendices or supplementary materials)을 작성한다. 부록의 각 절은 영문 알파벳을 사용하여 구분하는 것이 일반적이다.

B 부록 두번째 제목

필요한 경우 색인(index)을 작성한다.